

求解分数阶 Laplace 问题的 Fourier 复合神经网络方法

龚天¹, 许鹏博^{2,*}, 朱慧敏², 赵丽静^{1,*}

1. 西北工业大学数学与统计学院, 西安 710129

E-mail: gong_tian@mail.nwpu.edu.cn, zhaolj17@nwpu.edu.cn

2. 华东师范大学数学科学学院, 上海 200241

E-mail: pbxu@math.ecnu.edu.cn, 51265500069@stu.ecnu.edu.cn

摘要: 针对蕴含分数阶 Laplace 算子的扩散输运模型, 本文提出了一种基于 Fourier 变换的复合神经网络求解方法. 首先, 利用分数阶 Laplace 算子的 Fourier 域表示, 将非局域空间算子转化为频域代数乘子, 构建频域物理信息神经网络 (frequency-domain PINNs) 学习齐次演化过程; 进一步结合 Duhamel 原理, 将非齐次源项响应表示为时间卷积形式, 并采用 Fourier 神经算子 (Fourier Neural Operator, FNO) 学习源项到响应的全局映射. 通过两类网络输出的叠加, 实现对完整分数阶对流扩散过程的高精度近似. 一维和二维空间分数阶对流扩散问题的数值实验表明, 该方法能够有效处理不同分数阶参数下的扩散过程. 在光滑解算例中, 预测误差达到 10^{-4} – 10^{-3} 量级; 对于非正则解问题, 相比传统 PINNs 具有更好的误差控制能力; 二维实验进一步验证了该方法的适用性和鲁棒性. 研究表明, 融合频域物理约束与算子学习的复合神经网络框架, 为求解具有非局域特征的分数阶偏微分方程提供了一种有效方法.

关键词: 分数阶 Laplace 算子; 物理信息神经网络; Fourier 神经算子; 深度学习

A Fourier Composite Neural Network Method for Solving Fractional Laplace Problems

Tian Gong¹, Pengbo Xu^{2,*}, Huimin Zhu², Lijing Zhao^{1,*}

1. School of Mathematics and Statistics, Northwestern Polytechnical University, Xi'an 710129, P. R. China

E-mail: gong_tian@mail.nwpu.edu.cn, zhaolj17@nwpu.edu.cn

2. School of Mathematical Sciences, East China Normal University, Shanghai 200241, P. R. China

E-mail: pbxu@math.ecnu.edu.cn, 51265500069@stu.ecnu.edu.cn

Abstract: This paper proposes a composite neural network method based on the Fourier transform for solving diffusion and transport models involving fractional Laplace operators. First, the Fourier-domain representation of the fractional Laplace operator is used to convert the nonlocal spatial operator into an algebraic multiplier in the frequency domain, and frequency-domain physics-informed neural networks (PINNs) are constructed to learn the homogeneous evolution. Furthermore, Duhamel's principle is used to express the response to a nonhomogeneous source term as a temporal convolution, and a Fourier neural operator (FNO) is employed to learn the global mapping from the source term to its response. Superposing the outputs of the two types of networks yields a highly accurate approximation of the complete fractional advection-diffusion process. Numerical experiments on one- and two-dimensional space-fractional advection-diffusion problems show that the proposed method can effectively handle diffusion processes with different fractional orders. For examples with smooth solutions, the prediction errors are on the order of 10^{-4} – 10^{-3} . For problems with nonregular solutions, the method provides better error control than conventional PINNs. Two-dimensional experiments further demonstrate its applicability and robustness. These results indicate that the composite neural network framework, which combines physical constraints in the frequency domain with operator learning, provides an effective approach to solving fractional partial differential equations with nonlocal characteristics.

Key Words: Fractional Laplace operator; physics-informed neural networks; Fourier neural operator; deep learning

1 引言

1.1 研究背景与意义

扩散过程是描述物质、能量以及信息在介质中传输的重要数学模型, 广泛存在于自然科学与工程领域. 在经典扩散理论中, 粒子的运动通常满足高斯统计规律, 其均方位移与时间呈线性关系, 即 $\langle x^2 \rangle \propto t$, 对应于正常扩散过程. 然而, 随着实验观测技术的发展以及复杂系统研究的深入, 大量实际输运现象表现出与经典扩散理论不同的反常扩散特征, 例如非高斯分布、长程相关性以及跨尺度跃迁等现象 [1, 2]. 这些复杂行为广泛存在于多孔介

质输运、复杂流体以及生物系统等领域, 使得传统扩散模型难以准确描述实际物理过程.

为了刻画上述反常扩散现象, 空间分数阶扩散模型逐渐成为研究复杂输运问题的重要数学工具 [3, 4]. 通过引入空间分数阶导数, 特别是分数阶 Laplace 算子, 该模型能够有效描述粒子的长距离跳跃行为以及空间非局域效应. 针对广义 Dirichlet 边值问题, 即给定初值和 $u(x, t)|_{x \in \mathbb{R}^d \setminus \Omega}$, 本文讨论含有分数阶扩散算子的扩散输运问题, 一般形式表示为

$$\partial_t u(x, t) + \nabla \cdot (b(x, t)u(x, t)) = -c(-\Delta)^{\alpha/2}u(x, t) + f(x, t), \quad x \in \Omega \subset \mathbb{R}^d, \quad (1)$$

其中 $0 < \alpha \leq 2$ 表示分数阶阶数, $(-\Delta)^{\alpha/2}$ 为分数阶 Laplace 算子, 其奇异积分形式表示可参见 [5, 6]. 此时分

* 通讯作者: 许鹏博 (pbxu@math.ecnu.edu.cn)、赵丽静 (zhaolj17@nwpu.edu.cn).

数阶 Laplace 算子可以通过 Fourier 变换定义为

$$\mathcal{F}\left[(-\Delta)^{\alpha/2}u\right](k) = |k|^{\alpha}\hat{u}(k),$$

这也是从随机过程角度导出相关全空间方程的最初算子定义. 从随机过程角度来看, 分数阶 Laplace 算子对应具有长跳跃特征的 Lévy 过程生成元, 因此能够自然描述具有厚尾分布和非局域输运特征的复杂系统.

空间分数阶对流模型已经被应用于多个实际领域. 例如, 在多孔介质污染迁移问题中, 溶质传播过程常表现出明显的长尾扩散特征, 传统模型难以准确描述其迁移行为, 而分数阶模型能够有效捕捉其中的反常输运机制 [7]. 此外, 在分数阶 Fokker-Planck 方程以及生物医学反常扩散研究中, 分数阶模型也展现出了良好的描述能力 [8, 9].

然而, 相比经典整数阶偏微分方程, 空间分数阶方程的数值求解仍面临较大挑战. 一方面, 分数阶 Laplace 算子具有明显的非局域特征, 导致离散后产生全局耦合结构, 使计算复杂度和存储需求显著增加; 另一方面, 分数阶问题通常伴随着较低的解正则性和复杂的频谱结构, 使高维问题求解更加困难. 因此, 发展高效、稳定且具有高维适应能力的分数阶方程求解方法具有重要理论意义和应用价值.

1.2 研究现状

1.2.1 传统数值方法研究现状

针对空间分数阶对流扩散方程, 已有研究主要基于有限差分方法、有限元方法以及谱方法等传统数值框架展开. 有限差分方法通过构造适用于 Riesz 分数阶导数的离散格式, 实现了分数阶扩散问题的稳定求解 [10, 11]; 有限元方法利用变分形式处理复杂区域问题, 在理论分析和工程计算中得到了广泛应用 [12]; 谱方法则通过构造高阶基函数展开, 在提高计算精度方面具有明显优势 [13]. 此外, 针对复杂区域和二维问题, 研究 Laplace 进一步发展了非结构网格方法以及高效迭代算法, 以提高分数阶模型的计算效率 [14, 15].

尽管传统数值方法已经取得了大量研究成果, 但其在高维空间问题中的应用仍受到限制. 由于分数阶算子的全局耦合性质, 离散过程通常需要大量非局域积分计算; 随着空间维度增加, 计算规模呈快速增长趋势. 同时, 对于复杂参数条件下的分数阶问题, 传统方法往往需要针对具体方程设计离散格式, 降低了算法的通用性. 因此, 如何构建具有更强高维扩展能力和更高计算效率的求解框架, 仍是当前研究的重要问题.

1.2.2 深度学习研究方法研究现状

近年来, 深度学习方法逐渐成为偏微分方程数值求解的重要研究方向. 相比传统网格离散方法, 深度学习方法能够通过神经网络直接逼近连续函数或函数空间映射, 为复杂 PDE 问题提供了一种新的求解思路. 其中, 物理信息神经网络 (physics-informed neural networks, PINNs) 通过将控制方程残差、边界条件以及初始条件融入神经网络损失函数, 实现了物理约束下的无网格求解框架 [16, 17]. PINNs 已被广泛应用于流体力学、反问题以及复杂物理系统模拟等任务. 然而, 对于包含分数阶

算子的偏微分方程, 传统 PINNs 通常需要额外构造分数阶导数离散方法, 增加了计算复杂度.

另一方面, 算子学习方法旨在直接学习函数空间之间的映射关系, 为参数化 PDE 快速求解提供了新的技术路线. 其中, Fourier 神经算子 (Fourier neural operator, FNO) 利用 Fourier 变换提取全局空间特征, 在参数化偏微分方程求解中表现出了良好的泛化能力 [19]. 近年来, 研究者进一步将物理约束引入神经算子框架, 通过结合物理信息与算子学习方法提高模型的泛化能力和物理一致性 [20, 21]. 此外, DeepONet 等方法进一步发展了无限维函数映射学习理论, 为复杂算子近似提供了有效工具 [22, 23].

针对分数阶偏微分方程, Pang 等人提出了分数阶物理信息神经网络 (fractional physics-informed neural networks, fPINNs), 通过结合 PINNs 与分数阶算子离散方法, 实现了神经网络方法在分数阶问题中的推广 [25]. 随后, 相关研究进一步围绕高维问题、随机采样以及训练效率优化展开, 例如 Monte Carlo fPINNs 和高维 fractional PINNs 等方法 [26, 27]. 此外, 基于 Lévy 过程表示的深度学习方法也为高维分数阶 PDE 求解提供了新的思路 [28].

综上, 现有方法虽然在分数阶 PDE 求解方面取得了一定进展, 但仍存在一定不足. 一方面, PINNs 在处理分数阶非局域算子时仍依赖额外的离散计算, 限制了其在高维空间问题中的效率; 另一方面, FNO 等神经算子方法虽然具有优秀的全局信息提取能力, 但缺少明确的物理约束. 因此, 如何结合物理信息学习与神经算子学习优势, 充分利用分数阶问题的频域结构, 实现高效、高精度求解仍值得进一步研究.

1.3 本文研究内容

本文针对蕴含空间分数阶 Laplace 算子的对流扩散方程, 提出一种 PINNs 与 FNO 相结合的复合求解框架. 基于线性系统叠加原理, 将原问题的解分解为

$$u = u_1 + u_2,$$

其中 u_1 表示初值演化贡献, u_2 表示外部源项产生的响应.

对于齐次部分 u_1 , 本文利用问题的 Fourier 结构, 将分数阶 Laplace 算子转换为频域乘子形式. 避免直接在物理空间离散复杂的非局域算子. 通过在频域构造物理残差和初值约束, 利用 PINNs 学习频域演化过程, 并通过 Fourier 逆变换恢复空间域解.

对于非齐次部分 u_2 , 本文基于 Duhamel 原理将源项作用表示为时间积分形式, 并利用 FNO 学习源项到响应解之间的算子映射关系. 借助 FNO 对全局空间特征的表达能力, 实现对复杂补偿项的有效逼近.

最终, 通过两个分支结果叠加得到整体预测解:

$$u_{\theta}(x, t) = u_{1,\theta}(x, t) + u_{2,\theta}(x, t).$$

本文方法充分结合频域物理约束与神经算子学习的优势, 为高维分数阶对流扩散问题提供了一种新的数值求解框架.

2 Fourier 复合神经网络方法

2.1 问题分解与总体框架

为了更好的符号表达, 我们现将线性问题(1)中的系数 $b(x, t)$ 设为常数 μ , 并记:

$$\mathcal{A} := \partial_t + c(-\Delta)^{\alpha/2} + \mu \cdot \nabla. \quad (2)$$

由于(2)为线性问题, 可根据叠加原理将解分解为

$$u(x, t) = u_1(x, t) + u_2(x, t), \quad (3)$$

其中 u_1 解齐次初值问题

$$\begin{cases} \mathcal{A}u_1(x, t) = 0, & x \in \mathbb{R}^d, t \in (0, T], \\ u_1(x, 0) = u_0(x), & x \in \mathbb{R}^d; \end{cases} \quad (4)$$

u_2 解零初值非齐次问题

$$\begin{cases} \mathcal{A}u_2(x, t) = f(x, t), & x \in \mathbb{R}^d, t \in (0, T], \\ u_2(x, 0) = 0, & x \in \mathbb{R}^d. \end{cases} \quad (5)$$

这种分解的优势在于两个子问题的结构不同: u_1 的主要困难是分数阶算子的非局域演化, 可通过 Fourier 变换转化为频域常微分型约束; u_2 的主困难是源项的历史累积贡献, 可通过 Duhamel 原理写成卷积积分, 并由 FNO 近似其核算子. 总体思路的流程如图 1 所示. 首先, 训练频域 PINNs 得到 $\hat{u}_{1, \text{pred}}(k, t)$; 其次, 通过数值 Fourier 逆变换得到 $u_{1, \text{pred}}(x, t)$; 再次, 训练 FNO 得到 $u_{2, \text{pred}}(x, t)$; 最后, 以

$$u_{\text{pred}}(x, t) = u_{1, \text{pred}}(x, t) + u_{2, \text{pred}}(x, t) \quad (6)$$

作为最终预测.




图 1: Fourier 复合神经网络总体框架流程图

2.2 齐次分量的频域 PINNs 方法 [16, 17]

2.2.1 频域方程与实虚部分解

对(4)作空间 Fourier 变换, 采用归一化定义

$$\hat{u}(k, t) = \mathcal{F}[u](k, t) = \frac{1}{(2\pi)^{d/2}} \int_{\mathbb{R}^d} u(x, t) e^{-ix \cdot k} dx. \quad (7)$$

由(2), $\mathcal{F}[(-\Delta)^{\frac{\alpha}{2}} u] = |k|^{\alpha} \hat{u}$ 及 $\mathcal{F}[\nabla u] = ik \hat{u}$ 可得

$$\begin{cases} \partial_t \hat{u}_1(k, t) + c|k|^{\alpha} \hat{u}_1(k, t) + i\mu \cdot k \hat{u}_1(k, t) = 0, & k \in \mathbb{R}^d, t \in (0, T], \\ \hat{u}_1(k, 0) = \hat{u}_0(k), & k \in \mathbb{R}^d. \end{cases} \quad (8)$$

由于物理空间中的 u_1 为实值函数, 频域解一般为复值函数. 令

$$\hat{u}_1(k, t) = v(k, t) + iw(k, t). \quad (9)$$

此时分离方程(8)的实部虚部可知方程(8)等价于实值耦合系统:

$$\begin{cases} \partial_t v + c|k|^{\alpha} v - (\mu \cdot k)w = 0, \\ w(k, 0) = \text{Im} \hat{u}_0(k), \\ \partial_t w + c|k|^{\alpha} w + (\mu \cdot k)v = 0, \\ v(k, 0) = \text{Re} \hat{u}_0(k). \end{cases} \quad (10)$$

在频域空间下, 利用上述空间 Fourier 逆变换域, 实虚部分解, 将原问题转化为代数方程问题(10). 而 PINNs 正是可以较为准确地求解该问题的一种方法. 接下来回顾 PINNs 的具体架构.

2.2.2 一般 PINNs 网络架构与损失函数

为了说明本文中频域 PINNs 的构造方式, 我们先回顾一般物理信息神经网络求解偏微分方程初边值问题的基本思想, 见图 2.




图 2: Fourier 复合神经网络的频域 PINNs 网络架构

考虑如下形式的偏微分方程初边值问题:

$$\begin{cases} \mathcal{A}u(x, t) = f(x, t), & x \in \Omega, t \in (0, T], \\ u(x, 0) = u_0(x), & x \in \Omega, \\ \mathcal{B}u(x, t) = g(x, t), & x \in \partial\Omega, t \in (0, T], \end{cases} \quad (11)$$

其中 $\Omega \subset \mathbb{R}^d$ 为空间计算区域, $\mathcal{A}$ 表示控制方程中的微分算子, $\mathcal{B}$ 表示边界算子, u_0 与 g 分别为初值和边界数据.

PINNs 的核心思想是利用神经网络 $u_{\theta}(x, t)$ 作为未知解 $u(x, t)$ 的连续逼近, 并通过自动微分计算网络输出关于输入变量的导数, 从而在损失函数中同时约束方程残差、初始条件和边界条件. 设神经网络为

$$\mathcal{N}_{\theta} : (x, t) \in \mathbb{R}^{d+1} \mapsto u_{\theta}(x, t) \in \mathbb{R}, \quad (12)$$

其中 θ 表示所有待训练参数. 经典的 PINN 方法采用 L 层全连接前馈网络:

$$z^{(0)} = (x, t), \quad z^{(\ell)} = \sigma(W^{(\ell)}z^{(\ell-1)} + b^{(\ell)}), \quad \ell = 1, \dots, L-1, \quad (13)$$

末层采用线性输出:

$$u_{\theta}(x, t) = W^{(L)}z^{(L-1)} + b^{(L)}, \quad (14)$$

这里 $W^{(\ell)}$ 和 $b^{(\ell)}$ 分别为第 ℓ 层的权重矩阵与偏置向量, σ 为非线性激活函数. 由于 PDE 残差通常需要对网络输出求导, PINNs 中常选取 $\tanh$ 等光滑激活函数, 以保证自动微分过程的稳定性.

记内部残差点集、初值点集和边界点集分别为

$$\mathcal{P}_r = \{(x_i^r, t_i^r)\}_{i=1}^{N_r} \subset \Omega \times (0, T],$$

$$\mathcal{P}_{ic} = \{x_j^{ic}\}_{j=1}^{N_{ic}} \subset \Omega, \quad \mathcal{P}_{bc} = \{(x_m^{bc}, t_m^{bc})\}_{m=1}^{N_{bc}} \subset \partial\Omega \times (0, T].$$

由神经网络近似解 u_θ 构造方程残差:

$$r_\theta(x, t) = \mathcal{A}u_\theta(x, t) - f(x, t). \quad (15)$$

相应的方程残差损失、初值损失和边界损失分别定义为

$$\mathcal{L}_r(\theta) = \frac{1}{N_r} \sum_{i=1}^{N_r} |r_\theta(x_i^r, t_i^r)|^2, \quad (16)$$

$$\mathcal{L}_{ic}(\theta) = \frac{1}{N_{ic}} \sum_{j=1}^{N_{ic}} |u_\theta(x_j^{ic}, 0) - u_0(x_j^{ic})|^2, \quad (17)$$

$$\mathcal{L}_{bc}(\theta) = \frac{1}{N_{bc}} \sum_{m=1}^{N_{bc}} |Bu_\theta(x_m^{bc}, t_m^{bc}) - g(x_m^{bc}, t_m^{bc})|^2. \quad (18)$$

于是, 一般 PINNs 的训练目标可写为

$$\mathcal{L}_{PINN}(\theta) = \omega_r \mathcal{L}_r(\theta) + \omega_{ic} \mathcal{L}_{ic}(\theta) + \omega_{bc} \mathcal{L}_{bc}(\theta), \quad (19)$$

其中 ω_r 、 ω_{ic} 和 ω_{bc} 为不同损失项的权重参数. 在实际训练中, 这些权重可以固定选取, 也可以根据不同损失项的量级进行自适应调整. 通过最小化 (19), 神经网络不仅拟合初边值条件, 还在内部配点上满足控制方程, 从而得到满足物理约束的近似解.

2.2.3 频域的 PINNs 应用

下面在不改动网络架构的前提下将 PINNs 应用于频域方程 (10). 在频域 PINNs 的构造中, 主要考虑两类约束: 一是频域控制方程对应的方程残差约束, 二是由初始条件诱导得到的频域初值约束.

为说明损失函数的构造, 先以频域方程的实部为例进行讨论. 记神经网络输出的实部与虚部解的近似为

$$v_{\theta_1}(k, t) \approx \text{Re } \hat{u}_1(k, t), \quad w_{\theta_1}(k, t) \approx \text{Im } \hat{u}_1(k, t).$$

由频域方程的实虚部分解可知, 实部方程为

$$\partial_t v(k, t) + c|k|^\alpha v(k, t) - (\mu \cdot k)w(k, t) = 0, \quad k \in \Omega_k, \quad t \in (0, T]. \quad (20)$$

于是可由网络近似解构造实部残差:

$$r_v(k, t; \theta_1) = \partial_t v_{\theta_1}(k, t) + c|k|^\alpha v_{\theta_1}(k, t) - (\mu \cdot k)w_{\theta_1}(k, t), \quad (21)$$

其中 $\partial_t v_{\theta_1}$ 通过自动微分计算, 而分数阶 Laplace 项已经由 Fourier 变换转化为频域乘子 $|k|^\alpha$, 因此无需在物理空间中额外构造分数阶差分或奇异积分近似.

设残差采样点集为

$$\mathcal{P}_r = \{(k_i, t_i)\}_{i=1}^{N_r} \subset \Omega_k \times (0, T],$$

并定义频域解尺度

$$S_{\hat{u}} = |\hat{u}_0(0)| + \varepsilon, \quad (22)$$

其中 ε 为防止分母过小的正数. 为了降低不同频率区域内解幅值差异以及训练过程中数值过小对优化过程的影响, 本文对频域残差进行尺度归一化处理. 因此, 可以将实部方程残差损失定义为

$$\mathcal{L}_{eq}^v(\theta_1) = \frac{1}{N_r} \sum_{i=1}^{N_r} \left| \frac{r_v(k_i, t_i; \theta_1)}{S_{\hat{u}}} \right|^2. \quad (23)$$

另一方面, 齐次子问题的初始条件为 $u_1(x, 0) = u_0(x)$ 对其进行空间 Fourier 变换可得 $\hat{u}_1(k, 0) = \hat{u}_0(k)$ 因此, 实部满足 $v(k, 0) = \text{Re } \hat{u}_0(k)$. 设初值采样点集为

$$\mathcal{P}_{ic} = \{k_j^0\}_{j=1}^{N_{ic}} \subset \Omega_k,$$

则实部初值损失同样采用尺度归一化形式:

$$\mathcal{L}_{ic}^v(\theta_1) = \frac{1}{N_{ic}} \sum_{j=1}^{N_{ic}} \left| \frac{v_{\theta_1}(k_j^0, 0) - \text{Re } \hat{u}_0(k_j^0)}{S_{\hat{u}}} \right|^2. \quad (24)$$

记 ω_{eq}^v 与 ω_{ic}^v 分别表示实部方程残差损失和实部初值损失的权重. 因此, 仅考虑实部方程时, PINNs 的训练目标可写为

$$\mathcal{L}_{PINN}^v(\theta_1) = \omega_{eq}^v \mathcal{L}_{eq}^v(\theta_1) + \omega_{ic}^v \mathcal{L}_{ic}^v(\theta_1), \quad (25)$$

其中 ω_{eq}^v 与 ω_{ic}^v 分别为实部方程残差损失和实部初值损失的权重. 该损失函数中, $\mathcal{L}_{eq}^v$ 用于约束网络输出在频域中满足实部控制方程, $\mathcal{L}_{ic}^v$ 用于约束网络输出在 $t = 0$ 时刻满足由初值函数诱导的频域初始条件.

虚部方程的处理方式完全类似. 可类似的定义虚部方程残差损失 $\mathcal{L}_{eq}^w$ 与虚部初值损失 $\mathcal{L}_{ic}^w$.

最终, 频域 PINNs 分支的总损失函数定义为

$$\mathcal{L}_{PINN}(\theta_1) = \omega_{eq}^v \mathcal{L}_{eq}^v(\theta_1) + \omega_{ic}^v \mathcal{L}_{ic}^v(\theta_1) + \omega_{eq}^w \mathcal{L}_{eq}^w(\theta_1) + \omega_{ic}^w \mathcal{L}_{ic}^w(\theta_1). \quad (26)$$

通过最小化上述损失函数, 可以使网络输出

$$\hat{u}_{1, \theta_1}(k, t) = v_{\theta_1}(k, t) + iw_{\theta_1}(k, t).$$

在频域中同时满足控制方程和初始条件. 训练完成后, 再通过数值 Fourier 逆变换得到物理空间中的齐次解近似:

$$u_{1, \theta_1}(x, t) = \mathcal{F}^{-1}[\hat{u}_{1, \theta_1}(k, t)](x, t).$$

2.3 非齐次分量的 FNO 方法 [19]

2.3.1 源项响应算子与 FNO 建模思想

对于非齐次分量 u_2 , 本文考虑如下零初值问题:

$$\begin{cases} \mathcal{A}u_2(x, t) = f(x, t), & x \in \mathbb{R}^d, \quad t \in (0, T], \\ u_2(x, 0) = 0, & x \in \mathbb{R}^d, \end{cases} \quad (27)$$

其中 $\mathcal{A}$ 为线性空间分数阶扩散算子, $f(x, t)$ 为外部源项. 由于该问题的初始条件为零, 解 u_2 完全由源项 f 驱动产

生. 因此, 非齐次子问题可以理解为一个从源项函数到响应解函数的算子映射:

$$\mathcal{G}: f \mapsto u_2. \quad (28)$$

本文采用 Fourier Neural Operator (FNO) 近似该源项响应算子, 即

$$u_{2,\theta_2} = \mathcal{G}_{\theta_2}(f) \approx u_2, \quad (29)$$

其中 θ_2 为 FNO 分支中的可训练参数.

FNO 适用于该部分的主要原因来自 Duhamel 原理. 设 $K(x, t)$ 为线性演化半群对应的 Green 核, 则零初值非齐次问题的解可表示为

$$u_2(x, t) = \int_0^t \int_{\mathbb{R}^d} K(x - y, t - s) f(y, s) dy ds. \quad (30)$$

该式说明, 在任意时刻 t , 非齐次解 $u_2(x, t)$ 由历史时刻 $s \in [0, t]$ 上的源项 $f(\cdot, s)$ 经过演化核 $K(\cdot, t - s)$ 作用后累积得到. 对空间变量而言, 内层积分正是卷积形式:

$$\int_{\mathbb{R}^d} K(x - y, t - s) f(y, s) dy = [K(\cdot, t - s) * f(\cdot, s)](x).$$

进一步对时间区间作均匀离散, 令

$$t_i = i\Delta t, \quad \Delta t = \frac{T}{M}.$$

则有

$$u_2(x, t_i) \approx \sum_{j=0}^{i-1} \Delta t [K(\cdot, t_i - t_j) * f(\cdot, t_j)](x). \quad (31)$$

其中

$$K * f = \mathcal{F}^{-1}(\mathcal{F}[K] \cdot \mathcal{F}[f]). \quad (32)$$

因此, Duhamel 表示揭示了 $f \mapsto u_2$ 的两个重要结构: 第一, 源项响应具有时间累积性; 第二, 每一个历史时刻的源项贡献在空间上具有卷积形式. FNO 的谱卷积层正是通过 Fourier 变换 $\rightarrow$ 频域可学习乘子 $\rightarrow$ Fourier 逆变换来参数化卷积型核算子. 换言之, FNO 并不是简单地对离散数据作普通函数拟合, 而是在网络层中显式保留了卷积算子的频域乘子结构. 因此, 使用 FNO 学习 $\mathcal{G}: f \mapsto u_2$ 与 Duhamel 公式所揭示的源项响应机制是相匹配的.

需要说明的是, 真实的 Green 核 K 通常不在网络中显式构造. FNO 的作用是通过训练数据学习一个近似的源项响应算子 $\mathcal{G}_{\theta_2}$, 使其在给定源项 f 后能够直接输出对应的非齐次分量 u_2 . 这种做法避免了显式计算 Duhamel 积分中的高维卷积核, 同时保留了卷积结构所带来的频域计算优势.

2.3.2 FNO 网络结构介绍

FNO 采用“升维-谱卷积-降维”的结构. 首先, 将输入张量 a 通过逐点映射 P 提升到高维特征空间:

$$v_0(x, t) = P(a(x, t)), \quad (33)$$

其中 a 包含源项值和坐标信息, v_0 为 FNO 的初始隐变量.

随后, 网络堆叠若干个谱卷积层. 第 ℓ 个谱卷积层的形式为

$$v_{\ell+1} = \sigma(W_\ell v_\ell + \mathcal{F}^{-1}(R_\ell \cdot \mathcal{F}(v_\ell))), \quad \ell = 0, 1, \dots, L_f - 1, \quad (34)$$

其中, W_ℓ 为局部线性变换, 用于通道混合与局部信息传递; R_ℓ 为可学习的复值频域权重, 用于刻画全局卷积核; $\mathcal{F}$ 和 $\mathcal{F}^{-1}$ 分别表示离散 Fourier 变换及其逆变换; σ 为非线性激活函数, 实际计算中可取 GELU.

在谱卷积部分, 通常只保留有限个低频模态. 记

$$\hat{v}_\ell = \mathcal{F}(v_\ell).$$

则频域更新可写为

$$\hat{y}_\ell(k) = R_\ell(k) \hat{v}_\ell(k), \quad |k| \leq m, \quad (35)$$

而高频模态被截断或置零. 该低频截断策略的作用是用有限维参数近似主要的全局响应结构, 并降低计算成本. 经过 L_f 个谱卷积层后, 再通过逐点投影 Q 输出非齐次分量:

$$u_{2,\theta_2}(x, t) = Q(v_{L_f}(x, t)). \quad (36)$$

从结构上看, $W_\ell v_\ell$ 提供局部通道变换, $\mathcal{F}^{-1}(R_\ell \cdot \mathcal{F}(v_\ell))$ 提供全局卷积型作用, 二者共同构成了 FNO 对源项响应算子的近似能力.

2.3.3 输入输出与损失函数

与 PINNs 通过点集 $\mathcal{P}_r$ 、 $\mathcal{P}_{ic}$ 构造残差不同, FNO 的输入是离散函数样本, 即源项在时空网格上的张量表示. 设训练集为

$$\mathcal{D}_{FNO} = \left\{ \left(a^{(n)}, u_2^{(n)} \right) \right\}_{n=1}^{N_{\text{train}}}, \quad (37)$$

其中 $a^{(n)}$ 为输入张量, $u_2^{(n)}$ 为对应的非齐次解标签.

一维空间情形下, 设空间网格为 $\{x_s\}_{s=1}^{N_s}$, 时间网格为 $\{t_i\}_{i=0}^M$, 可取

$$a(x_s, t_i) = (f(x_s, t_i), x_s, t_i), \quad a \in \mathbb{R}^{(M+1) \times N_s \times 3}. \quad (38)$$

二维空间情形下, 设空间网格为 $\{(x_p, y_q)\}_{p=1, q=1}^{N_x, N_y}$, 可取

$$a(x_p, y_q, t_i) = (f(x_p, y_q, t_i), x_p, y_q, t_i), \quad a \in \mathbb{R}^{(M+1) \times N_x \times N_y \times 4}. \quad (39)$$

若需要学习不同分数阶阶数下的响应, 也可以将 α 作为额外常数通道加入输入.

FNO 的输出定义为非齐次解在同一离散时空网格上的近似:

$$u_{2,\theta_2}^{(n)} = \mathcal{G}_{\theta_2} \left(a^{(n)} \right). \quad (40)$$

因此, 一维情形下

$$u_{2,\theta_2}^{(n)} \in \mathbb{R}^{(M+1) \times N_s},$$

二维情形下

$$u_{2,\theta_2}^{(n)} \in \mathbb{R}^{(M+1) \times N_x \times N_y}.$$

设 $\mathcal{D}_h$ 表示离散时空网格点集合。类似于 PINN 中采用的尺度归一化, 对于第 n 个训练样本, 定义非齐次尺度

$$S_{u_2}^{(n)} = \frac{1}{|\mathcal{D}_h|} \sum_{(x,t) \in \mathcal{D}_h} |u_2^{(n)}(x,t)| + \varepsilon, \quad (41)$$

其中 ε 为防止分母过小的正数。则 FNO 输出响应的尺度归一化损失定义为

$$\mathcal{L}_{u_2}(\theta_2) = \frac{1}{N_{\text{train}}} \sum_{n=1}^{N_{\text{train}}} \frac{1}{|\mathcal{D}_h|} \sum_{(x,t) \in \mathcal{D}_h} \left| \frac{\mathcal{G}_{\theta_2}(a^{(n)})(x,t) - u_2^{(n)}(x,t)}{S_{u_2}^{(n)}} \right|^2. \quad (42)$$

2.4 PINNs-FNO 耦合策略

在本文方法中, 问题的齐次部分由频域 PINNs 分支给出:

$$\hat{u}_{1,\theta_1}(k,t) = v_{\theta_1}(k,t) + iw_{\theta_1}(k,t),$$

并通过数值 Fourier 逆变换得到物理空间中的预测

$$u_{1,\theta_1}(x,t) = \mathcal{F}^{-1}[\hat{u}_{1,\theta_1}(k,t)](x,t); \quad (43)$$

非齐次部分由 FNO 分支给出:

$$u_{2,\theta_2}(x,t) = \mathcal{G}_{\theta_2}(a)(x,t), \quad (44)$$

其中 a 为由源项 f 及坐标信息构成的输入张量。

最终, 本文采用严格线性叠加形式构造总解预测:

$$u_{\theta}(x,t) = u_{1,\theta_1}(x,t) + u_{2,\theta_2}(x,t). \quad (45)$$

该耦合方式与原方程的线性分解完全一致。这样可以保持模型结构的可解释性, 使总误差能够自然分解为齐次分支误差、非齐次分支误差以及数值 Fourier 逆变换误差等部分。

Algorithm 1 基于频域 PINNs 与 FNO 的复合求解算法

- 1: 输入: 初值函数 u_0 , 源项函数 f ;
- 2: 输入: 频域残差点集 $\mathcal{P}_r$, 频域初值点集 $\mathcal{P}_{ic}$, FNO 训练集 $\mathcal{D}_{FNO} = \{(a^{(n)}, u_2^{(n)})\}_{n=1}^{N_{\text{train}}}$
- 3: 输出: 总解预测 $u_{\theta}(x,t)$.
- 4: **Step 1:** 齐次分量的频域 PINNs 近似
- 5: 在 $\mathcal{P}_r$ 与 $\mathcal{P}_{ic}$ 上构造频域残差损失与初值损失:
$$\mathcal{L}_{PINN}(\theta_1) = \omega_{eq}^v \mathcal{L}_{eq}^v(\theta_1) + \omega_{ic}^v \mathcal{L}_{ic}^v(\theta_1) + \omega_{eq}^w \mathcal{L}_{eq}^w(\theta_1) + \omega_{ic}^w \mathcal{L}_{ic}^w(\theta_1).$$
- 6: 优化 PINNs 参数: $\theta_1^* = \arg \min_{\theta_1} \mathcal{L}_{PINN}(\theta_1)$.
- 7: 通过数值 Fourier 逆变换得到齐次分量预测: $u_{1,\theta_1^*}(x,t) = \mathcal{F}^{-1}[\hat{u}_{1,\theta_1^*}](x,t)$.
- 8: **Step 2:** 非齐次分量的 FNO 算子学习
- 9: 构造 FNO 输入张量 a , 其由源项 f 、坐标变量组成即 $a = a(f, x, t)$
- 10: 构造 FNO 算子网络 $\mathcal{G}_{\theta_2}: a \mapsto u_{2,\theta_2}$.
- 11: 在训练集 $\mathcal{D}_{FNO}$ 上定义监督损失:
$$\mathcal{L}_{u_2}(\theta_2) = \frac{1}{N_{\text{train}}} \sum_{n=1}^{N_{\text{train}}} \frac{1}{|\mathcal{D}_h|} \sum_{(x,t) \in \mathcal{D}_h} \left| \frac{\mathcal{G}_{\theta_2}(a^{(n)})(x,t) - u_2^{(n)}(x,t)}{S_{u_2}^{(n)}} \right|^2.$$
- 12: 优化 FNO 参数: $\theta_2^* = \arg \min_{\theta_2} \mathcal{L}_{FNO}(\theta_2)$.
- 13: 得到非齐次分量预测: $u_{2,\theta_2^*}(x,t) = \mathcal{G}_{\theta_2^*}(a)(x,t)$.
- 14: **返回:** $u_{\theta}(x,t) = u_{1,\theta_1^*}(x,t) + u_{2,\theta_2^*}(x,t)$.

3 数值实验

本节通过四个典型数值算例验证所提出方法求解分数阶 Laplace 问题的有效性。所选算例分别包括一维光滑解析解问题、一维含输运项的分数阶扩散问题、一维非正则解问题以及二维分数阶扩散问题。

所有实验均采用解析解作为参考解, 并通过平均绝对误差 (MAE) 和均方根误差 (RMSE) 评价数值结果的准确性。

$$\text{MAE} = \frac{1}{N} \sum_{i=1}^N |u_i - \tilde{u}_i|, \quad (46)$$

$$\text{RMSE} = \sqrt{\frac{1}{N} \sum_{i=1}^N (u_i - \tilde{u}_i)^2}. \quad (47)$$

3.1 实验参数设置

除特别说明外, 所有数值实验采用统一参数设置, 具体参数如表 1 所示。

表 1: 一维数值实验参数设置

设置项	网络结构	训练参数
	PINN(u_1)	FNO(u_2)
网络结构	FNN	Fourier Neural Operator
输入变量	(k, t)	(f, x, t)
输出变量	$(Re(\hat{u}_1, \theta_1), Im(\hat{u}_1, \theta_1))$	$u_{2,\theta_2}(x, t)$
隐藏层数量	5	4
隐藏维度	64	64
激活函数	GELU	GELU
Fourier modes	-	16
Lift 层	-	3 $\rightarrow$ 64
Projection 层	-	64 $\rightarrow$ 128 $\rightarrow$ 1
训练参数	PINN(u_1)	FNO(u_2)
优化器	AdamW	Adam
学习率	3×10^{-4}	10^{-3}
权重衰减	10^{-6}	10^{-6}
训练轮数	3000	3000
采样方式	随机频域配点	规则时空网格
方程残差采样点	$B_{\text{res}} = 512$	-
初值采样点	$B_{\text{ic}} = 512$	-
空间网格点	-	$S = 200$
时间步数	-	$M = 80$
频率采样点	$N_K = 80$	-
最大频率	$K_{\text{max}} = 8$	-

3.2 一维光滑解问题

首先考虑如下空间分数阶扩散方程:

$$\begin{cases} \frac{\partial u(x,t)}{\partial t} + c(-\Delta)^{\alpha/2} u(x,t) = f(x,t), & x \in \Omega = (0,1), t \in (0,1], \\ u(x,0) = x^3(1-x)^3, \\ u(x,t)|_{x \in \mathbb{R}^1 \setminus \Omega} = 0, \end{cases} \quad (48)$$

其中源项 $f(x,t)$ 为

$$\begin{aligned} f(x,t) = & \frac{t+1}{2 \cos(\pi\alpha/2)} \left[\frac{\Gamma(4)}{\Gamma(4-\alpha)} (x^{3-\alpha} + (1-x)^{3-\alpha}) - \frac{3\Gamma(5)}{\Gamma(5-\alpha)} (x^{4-\alpha} + (1-x)^{4-\alpha}) \right. \\ & \left. + \frac{3\Gamma(6)}{\Gamma(6-\alpha)} (x^{5-\alpha} + (1-x)^{5-\alpha}) - \frac{\Gamma(7)}{\Gamma(7-\alpha)} (x^{6-\alpha} + (1-x)^{6-\alpha}) \right] + x^3(1-x)^3. \end{aligned}$$

该问题有精确的解析解

$$u(x,t) = x^3(1-x)^3(t+1).$$

此解光滑且形式简单, 能排除问题本身的复杂性干扰, 使我们能专注于分析算法参数的影响。

现在对问题 (48), 取定上面的源项 $f(x,t)$, 应该通过算法求解得到 $u(x,t)$. 同时注意到 u_1 子问题在频域上有解析解, 即

$$\begin{cases} \frac{\partial u_1(x,t)}{\partial t} + c(-\Delta)^{\alpha/2} u_1(x,t) = 0 \\ u_1(x,0) = x^3(1-x)^3 \end{cases} \Leftrightarrow \begin{cases} \frac{\partial \hat{u}_1(k,t)}{\partial t} + c|k|^{\alpha} \hat{u}_1(k,t) = 0 \\ \hat{u}_1(k,0) = \mathcal{F}\{x^3(1-x)^3\} \end{cases} \Rightarrow \hat{u}_1(k,t) = e^{-c|k|^{\alpha}t} \hat{u}_1(k,0).$$

这样 u_1 的参考解将采用上述解析解的 Fourier 逆变换的数值结果, u_2 的参考解可以采用精确的解析解减 u_1 . 因此后续的数值算例中都可以计算得到 u_1, u_2, u 的参考解与预测解之间的误差。




图 3: 问题 (48) 中 $\alpha = 1.6$ 时 u_1 、 u_2 以及整体解的绝对误差分布。

不同分数阶参数下的误差结果汇总如表 2 所示。

表 2: 问题 (48) 不同分数阶参数下的误差结果

α	MAE(u_1)	MAE(u_2)	MAE(u)	RMSE(u)
0.4	1.7355×10^{-5}	2.8520×10^{-5}	2.3193×10^{-5}	2.7040×10^{-5}
0.8	7.4952×10^{-6}	8.4187×10^{-6}	3.5695×10^{-6}	5.2454×10^{-6}
1.2	3.1050×10^{-6}	5.9060×10^{-6}	5.9080×10^{-6}	7.7459×10^{-6}
1.6	6.5680×10^{-6}	1.0046×10^{-5}	8.3481×10^{-6}	1.1082×10^{-5}
2.0	9.9566×10^{-6}	9.7281×10^{-6}	5.2752×10^{-6}	6.7877×10^{-6}

图 3 给出了分解项 u_1 、 u_2 以及最终解的误差分布。表 2 给出了不同分数阶参数下算法的误差结果。可以看出, 在不同阶数条件下, 所提出方法均能够保持较高的计算精度, 整体解的平均绝对误差均低于 10^{-4} 。其中, 当 $\alpha = 0.8$ 和 $\alpha = 2.0$ 时, 整体误差达到较低水平, 分别取得 3.5695×10^{-6} 和 5.2752×10^{-6} 的 MAE, 说明该方法对于不同分数阶扩散算子均具有较好的适应能力。

3.3 含输运项的分数阶扩散问题

进一步, 我们考虑带有输运项的分数阶扩散方程:

$$\begin{cases} \frac{\partial u(x, t)}{\partial t} + c(-\Delta)^{\alpha/2} u(x, t) + \nu \nabla u(x, t) = f(x, t), & x \in \Omega = (0, 1), t \in (0, 1], \\ u(x, 0) = x^3(1-x)^3, \\ u(x, t)|_{x \in \mathbb{R}^1 \setminus \Omega} = 0, \end{cases} \quad (49)$$

其中取流速参数 $\nu = 1$, 源项 $f(x, t)$ 为:

$$\begin{aligned} f(x, t) = & \frac{t+1}{2\cos(\pi\alpha/2)} \left[\frac{\Gamma(4)}{\Gamma(4-\alpha)} (x^{3-\alpha} + (1-x)^{3-\alpha}) - \frac{3\Gamma(5)}{\Gamma(5-\alpha)} (x^{4-\alpha} + (1-x)^{4-\alpha}) \right. \\ & \left. + \frac{3\Gamma(6)}{\Gamma(6-\alpha)} (x^{5-\alpha} + (1-x)^{5-\alpha}) - \frac{\Gamma(7)}{\Gamma(7-\alpha)} (x^{6-\alpha} + (1-x)^{6-\alpha}) \right] \\ & + x^3(1-x)^3 + (t+1)[3x^2(1-x)^3 - 3x^3(1-x)^2]. \end{aligned}$$

该问题的解析解仍为

$$u(x, t) = x^3(1-x)^3(t+1). \quad (50)$$

相比于问题 (48), 该问题增加了一阶输运项。在 Fourier 空间中, 输运项对应复数频谱信息, 因此该算例进一步检验方法对于复杂频域结构问题的适应能力。




图 4: 问题 (49) 中误差分布结果。

误差结果如图 4 所示。结果表明, 在引入输运项后, 数值方法仍能够保持稳定的求解精度。

表 3: 问题 (49) 不同分数阶参数下的误差结果

α	MAE(u_1)	MAE(u_2)	MAE(u)	RMSE(u)
0.4	1.8880×10^{-5}	2.0906×10^{-5}	7.8614×10^{-6}	1.2365×10^{-5}
0.8	1.1003×10^{-5}	1.5126×10^{-5}	8.9397×10^{-6}	1.5965×10^{-5}
1.2	6.6327×10^{-6}	1.4150×10^{-5}	1.2738×10^{-5}	2.0480×10^{-5}
1.6	1.2159×10^{-5}	1.4426×10^{-5}	8.8529×10^{-6}	1.6960×10^{-5}
2.0	1.6889×10^{-5}	3.6104×10^{-5}	3.6539×10^{-5}	4.0784×10^{-5}

表 3 给出了不同分数阶参数下的误差结果。可以看出, 在不同 α 条件下, 所提出方法均能够保持较好的计算精度。整体解的 MAE 均保持在 10^{-5} 数量级以内 (除 $\alpha = 2.0$ 外), 说明该方法对于不同分数阶扩散算子具有较好的适应性。当 $\alpha = 0.4$ 时, 整体解取得最低误差, 其 MAE 和 RMSE 分别为 7.8614×10^{-6} 和 1.2365×10^{-5} 。随着分数阶阶数增大, 误差整体呈现一定增长趋势, 这主要由于高阶分数扩散算子对应的频域衰减特性发生变化, 使得 u_2 子问题需要学习更加复杂的补偿项。

3.4 一维非正则解问题

为了测试方法对于低正则性解的适应能力, 考虑如下问题

$$\begin{cases} \frac{\partial u(x, t)}{\partial t} + c(-\Delta)^{\alpha/2} u(x, t) = 1, & x \in \Omega = (-1, 1), t \in (0, 1], \\ u(x, 0) = g(x), \\ u(x, t)|_{x \in \mathbb{R}^1 \setminus \Omega} = 0, \end{cases} \quad (51)$$

其中初值函数 $g(x)$ 取

$$g(x) = \frac{2^{-\alpha}\Gamma(\frac{1}{2})}{\Gamma(\frac{1}{2} + \frac{\alpha}{2})\Gamma(1 + \frac{\alpha}{2})} (1-x^2)^{\alpha/2}. \quad (52)$$

此问题的解析解为

$$u(x, t) = (t+1)g(x). \quad (53)$$

其中, 初值函数 $g(x)$ 采用零外值积分型分数阶 Laplace 算子的经典构造形式 [6]。根据相关结果有:

$$(-\Delta)^{\alpha/2} g(x) = 1. \quad (54)$$

因此可得源项为

$$f(x, t) = g(x) + c(t+1).$$

由于该解在边界附近具有分数阶特征, 因此该算例用于检验方法处理非正则问题的能力。




图 5: 问题 (51) 非正则解问题的误差分布。

表 4: 问题 (51) 不同分数阶参数下的误差结果

α	MAE(u_1)	MAE(u_2)	MAE(u)	RMSE(u)
0.4	2.6470×10^{-3}	5.0263×10^{-2}	4.9711×10^{-2}	7.2753×10^{-2}
0.8	9.8601×10^{-4}	1.7790×10^{-3}	1.2062×10^{-3}	2.1225×10^{-3}
1.2	5.5261×10^{-4}	2.4112×10^{-1}	2.4120×10^{-1}	2.7776×10^{-1}
1.6	3.1993×10^{-4}	4.2444×10^{-3}	4.1585×10^{-3}	5.2214×10^{-3}
2.0	3.3954×10^{-4}	3.4833×10^{-3}	3.6136×10^{-3}	4.5242×10^{-3}

表 4 给出了问题 (51) 在不同分数阶参数下的计算结果. 由于该算例采用非正则初值函数, 其对应的补偿项 u_2 在频域中包含更加复杂的高频信息, 因此整体误差相较于前两个算例有所增加. 从表中可以看出, 除 $\alpha = 1.2$ 情况外, 算法均能够保持较好的计算精度. 当 $\alpha = 2.0$ 时, 整体解取得 3.6136×10^{-3} 的 MAE 和 4.5242×10^{-3} 的 RMSE. 结果表明, 尽管非正则初值增加了问题求解难度, 所提出的频域分解方法仍然能够有效捕捉主要解结构. 对于 $\alpha = 1.2$ 情况, 由于 u_2 分支误差明显增大, 导致整体误差达到 10^{-1} 数量级. 这说明在部分分数阶参数条件下, 补偿项学习难度增加, 仍存在进一步优化 FNO 分支表示能力的空间.

3.5 二维分数阶扩散问题

为了进一步验证所提出方法在高维空间问题中的适用性, 考虑二维分数阶扩散方程:

$$\begin{cases} \frac{\partial u(\mathbf{x}, t)}{\partial t} + c(-\Delta)^{\alpha/2} u(\mathbf{x}, t) = f(\mathbf{x}, t), & \mathbf{x} \in \mathbb{R}^2, t \in (0, 1], \\ u(\mathbf{x}, 0) = \exp(-|\mathbf{x}|^2/2), \end{cases} \quad (55)$$

其中 $\mathbf{x} = (x, y)$ 表示二维空间变量.

该算例选取二维 Gaussian 函数作为初始条件, 并构造相应源项使其满足给定解析解. 此处, 我们选取的解析解为

$$u(\mathbf{x}, t) = (t + 1) \exp(-|\mathbf{x}|^2/2).$$

此时可以计算得到源项: 因此源项为

$$f(\mathbf{x}, t) = e^{-r^2/2} + c(t + 1) \int_0^\infty k^{\alpha+1} e^{-k^2/2} J_0(kr) dk \quad (56)$$

二维算例中, 网络主体结构与一维实验保持一致, 仅针对二维空间变量进行扩展. 具体而言, 频域 PINN 的输入由 (k, t) 扩展为 (k_x, k_y, t) , FNO 的输入由 (f, x, t) 扩展为 (f, x, y, t) . 主体参数如下表所示.

表 5: 二维算例扩展参数设置

设置项	PINN(u_1)	FNO(u_2)
输入变量	(k_x, k_y, t)	(f, x, y, t)
输出变量	$(\text{Re}(\hat{u}_1), \text{Im}(\hat{u}_1))$	$g(x, y, t)$
方程残差点	$N_{eq} = 4096$	-
初值约束点	$N_{ic} = 4096$	-
空间网格	-	64×64
时间步数	-	$M = 80$
频率截断	$K_{\max} = 8$	-
二维频率采样	$N_{K_x} \times N_{K_y} = 64 \times 64$	-




图 6: 问题 (55) 二维分数阶扩散问题中 u_1 、 u_2 分支以及整体解的误差验证.

表 6: 问题 (55) 不同分数阶参数下的误差结果

α	MAE(u_1)	MAE(u_2)	MAE(u)	RMSE(u)
0.4	4.6958×10^{-3}	4.5853×10^{-3}	3.0741×10^{-4}	9.4031×10^{-4}
0.8	7.0409×10^{-3}	6.8995×10^{-3}	3.0442×10^{-4}	1.3494×10^{-3}
1.2	1.0532×10^{-2}	1.0367×10^{-2}	2.9379×10^{-4}	1.9743×10^{-3}
1.6	2.7828×10^{-2}	2.7365×10^{-2}	5.8675×10^{-4}	7.4874×10^{-3}
2.0	4.4947×10^{-2}	4.4036×10^{-2}	1.3019×10^{-3}	1.5208×10^{-2}

表 6 给出了问题 (55) 在不同分数阶参数下各分支及整体解的误差结果. 从表中可以看出, 随着分数阶参数 α 的变化, 频域 PINN 分支 u_1 与 FNO 补偿分支 u_2 的误差均有所变化. 当 $\alpha = 0.4, 0.8, 1.2$ 时, 两个分支的 MAE 均保持在 10^{-2} 数量级以内, 而经过两个分支叠加后, 整体解误差均降低至 10^{-4} 数量级, 说明所提出的频域分解策略能够有效利用不同网络结构的优势, 实现对二维分数阶扩散过程的高精度逼近.

进一步分析可知, 随着 α 增大, u_1 分支误差逐渐增加. 当 $\alpha = 2.0$ 时, u_1 与 u_2 的 MAE 分别达到 4.4947×10^{-2} 和 4.4036×10^{-2} . 这是由于较大的分数阶参数增强了频域中的高频衰减特性, 使得有限频率范围内的谱信息更加复杂, 从而增加了频域 PINN 和 FNO 分支的学习难度.

然而, 最终整体解仍保持较好的计算精度. 在所有测试参数下, 整体 MAE 均控制在 10^{-3} 数量级以内, 其中 $\alpha = 1.2$ 时取得最低误差 2.9379×10^{-4} . 当 $\alpha = 2.0$ 时, 虽然两个子分支误差有所增加, 但整体解仍取得 1.3019×10^{-3} 的 MAE 和 1.5208×10^{-2} 的 RMSE, 表明两个分支之间具有较好的误差补偿能力.

综上, 该二维算例验证了所提出方法在高维分数阶 Laplace 问题中的有效性. 通过将齐次演化部分与源项补偿部分分别交由频域 PINN 和 FNO 学习, 可以降低单一网络直接逼近复杂分数阶算子的困难, 提高方法对于不

同分数阶参数问题的适应能力。

4 结论

本文针对空间分数阶 Laplace 算子问题,提出了一种基于 Fourier 变换的复合神经网络求解框架。该方法首先利用 Fourier 变换将分数阶 Laplace 算子转换为频域乘子形式,从而避免了物理空间中非局域积分计算带来的高额计算成本。在此基础上,通过解的线性分解,将整体问题划分为齐次演化部分和源项响应部分:其中齐次部分采用频域 PINNs 进行学习,通过物理方程约束保证预测结果满足分数阶动力学规律;非齐次部分依据 Duhamel 原理表示为时间卷积形式,并利用 FNO 学习源项到系统响应之间的非局部映射关系。最终通过两个分支的严格叠加得到完整解。

本文针对不同类型的分数阶扩散输运问题进行了数值验证。实验结果表明,在一维光滑算例中,所提出方法能够达到 10^{-4} – 10^{-3} 量级的预测误差;对于包含非正则特征的分数阶扩散问题,相比传统 PINNs 方法具有更稳定的误差表现;在二维扩散问题中,该方法仍能够保持较高的计算精度,并且对于不同分数阶参数具有较好的适应能力。上述结果说明,通过结合频域物理约束和神经算子学习,可以有效降低单一神经网络直接逼近复杂分数阶算子的困难,提高模型对于非局域扩散过程的表达能力。

尽管本文方法取得了一定效果,但仍存在进一步改进空间。一方面,当前研究主要针对结构较简单的分数阶对流扩散问题,对于复杂边界条件、变系数分数阶算子以及更加复杂的物理约束情形仍需进一步研究。另一方面,网络训练效率、误差理论分析以及参数选择策略仍有待完善。

未来工作将重点围绕以下几个方向展开:(1)研究复杂区域和复杂边界条件下复合神经网络方法的推广;(2)探索适用于变系数、非线性分数阶偏微分方程的更加灵活的网络结构;(3)结合自适应采样、误差估计以及理论分析方法,提高模型训练效率和预测可靠性;(4)进一步验证该方法在实际反常扩散问题,如多孔介质输运、湍流扩散以及复杂动力系统中的应用价值。

参考文献

- [1] Metzler R, Klafter J. The random walk's guide to anomalous diffusion: a fractional dynamics approach[J]. *Physics Reports*, 2000, 339(1): 1–77.
- [2] Applebaum D. *Lévy Processes and Stochastic Calculus*[M]. Cambridge University Press, 2009.
- [3] Benson D A, Wheatcraft S W, Meerschaert M M. The fractional-order governing equation of Lévy motion[J]. *Water Resources Research*, 2000, 36(6): 1413–1423.
- [4] Metzler R, Klafter J. The restaurant at the end of the random walk: recent developments in the description of anomalous transport by fractional dynamics[J]. *Journal of Physics A: Mathematical and General*, 2004, 37(31): 161–208.
- [5] Lischke A, Pang G F, Gulian M, et al. What is the fractional Laplacian? A comparative review with new results[J]. *Journal of Computational Physics*, 2020, 404: 109009.
- [6] Dyda B. Fractional calculus for power functions and eigenvalues of the fractional Laplacian[J]. *Fractional Calculus and Applied Analysis*, 2012, 15(4): 536–555.

- [7] Benson D A, Schumer R, Meerschaert M M, et al. Fractional dispersion, Lévy motion, and the MADE tracer experiment[J]. *Transport in Porous Media*, 2001, 42: 211–240.
- [8] Liu F, Anh V, Turner I. Numerical solution of the space fractional Fokker-Planck equation[J]. *Journal of Computational and Applied Mathematics*, 2004, 166(1): 209–219.
- [9] Zhou X J, Gao Q, Abdullah O, et al. Studies of anomalous diffusion in the human brain using fractional order calculus[J]. *Magnetic Resonance in Medicine*, 2010, 63(3): 562–569.
- [10] Liu F, Zhuang P, Anh V, et al. Stability and convergence of the difference methods for the space-time fractional advection-diffusion equation[J]. *Applied Mathematics and Computation*, 2007, 191(1): 12–20.
- [11] Arshad S, Huang J, Khaliq A Q, et al. Trapezoidal scheme for time-space fractional diffusion equation with Riesz derivative[J]. *Journal of Computational Physics*, 2017, 350: 1–15.
- [12] Acosta G, Borthagaray J P. A fractional Laplace equation: regularity of solutions and finite element approximations[J]. *SIAM Journal on Numerical Analysis*, 2017, 55(2): 472–495.
- [13] Zayernouri M, Karniadakis G E. Fractional spectral collocation method[J]. *SIAM Journal on Scientific Computing*, 2014, 36(1): 40–62.
- [14] Feng L, Liu F, Turner I, et al. Unstructured mesh finite difference/finite element method for the 2D time-space Riesz fractional diffusion equation on irregular convex domains[J]. *Applied Mathematical Modelling*, 2018, 59: 441–463.
- [15] Cheng X, Duan J, Li D. A novel compact ADI scheme for two-dimensional Riesz space fractional nonlinear reaction-diffusion equations[J]. *Applied Mathematics and Computation*, 2019, 346: 452–464.
- [16] Brunton S L, Kutz J N. Machine learning for partial differential equations[J]. *arXiv preprint arXiv:2303.17078*, 2023.
- [17] Raissi M, Perdikaris P, Karniadakis G E. Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations[J]. *Journal of Computational Physics*, 2019, 378: 686–707.
- [18] Lu L, Meng X, Mao Z, et al. DeepXDE: A deep learning library for solving differential equations[J]. *SIAM Review*, 2021, 63(1): 208–228.
- [19] Li Z Y, Kovachki N, Azizzadenesheli K, et al. Fourier neural operator for parametric partial differential equations[C]. *International Conference on Learning Representations*, 2021.
- [20] Fang Z, Wang S, Perdikaris P. Learning Only on Boundaries: A Physics-Informed Neural Operator for Solving Parametric Partial Differential Equations in Complex Geometries[J]. *Neural Computation*, 2024, 36(3): 475–498.
- [21] Li Z Y, Zheng H, Kovachki N, et al. Physics-informed neural operator for learning partial differential equations[J]. *ACM/IMS Journal of Data Science*, 2024, 1(3): 1–27.
- [22] Lu L, Jin P Z, Pang G F, et al. Learning nonlinear operators via DeepONet based on the universal approximation theorem of operators[J]. *Nature Machine Intelligence*, 2021, 3: 218–229.
- [23] Li Z Y, Kovachki N, Azizzadenesheli K, et al. Neural operator: Graph kernel network for partial differential equations[J]. *arXiv preprint arXiv:2003.03485*, 2020.
- [24] Wang S, Sankaran S, Wang H, et al. An expert's guide to training physics-informed neural networks[J]. *arXiv preprint arXiv:2308.08468*, 2023.
- [25] Pang G F, Lu L, Karniadakis G E. fPINNs: Fractional

- physics-informed neural networks[J]. *SIAM Journal on Scientific Computing*, 2019, 41(4): 2603–2626.
- [26] Guo L, Wu H, Yu X, et al. Monte Carlo fPINNs: Deep learning method for forward and inverse problems involving high dimensional fractional partial differential equations[J]. *Computer Methods in Applied Mechanics and Engineering*, 2022, 400: 115523.
- [27] Hu Z, Kawaguchi K, Zhang Z, et al. Tackling the curse of dimensionality in fractional and tempered fractional PDEs with physics-informed neural networks[J]. *arXiv preprint arXiv:2406.11708*, 2024.
- [28] Arif K, Xi G J, Wang H, et al. Deep learning for high-dimensional PDEs with fat-tailed Lévy measure[J]. *Journal of Computational Physics*, 2025, 541: 114327.